

Софтверски алгоритми у системима аутоматског управљања

Пројекат

Реконструкција радарског сигнала

Огњен Живковић

RA99/2023

1. О проблему

Пројектни задатак био је реконструкција радарског сигнала који се прима преко 29 антена. Проблем симулира изненадне кварове и отказивања која се могу јавити на антенама или у преносној мрежи антена, на пример услед напонских скокова, прекида кабла или оштећења антенских склопова. Због тога је важно да успешно реконструишемо радарски сигнал који нам је од значаја.

Кварови су у изради задатка вештачки симулирани маскирањем произвољног броја антена (1-10) маскирана антена представља квар, па се вредност њеног примљеног сигнала поставља на нулу. Овако маскиран сигнал потом се прослеђује моделу на реконструкцију.

Проблем је решен регресионо, модел реконструише сигнал и прослеђује га систему на даљу обраду. Класификација је разматрана као могуће проширење, али није реализована у овом раду. Циљ реконструкције је да систем, и поред отказалих антена, може да настави процену положаја детектованих објеката.

Додатна замисао била је да се реконструкција доведе до нивоа на ком се из обновљеног сигнала могу препознати и долазни углови. Долазни углови говоре колико је објеката радарски систем детектовао и где се они налазе у односу на антене.

Како је проблем решен? Коришћен је stacking ансамбла. За разлику од bagging-a и boosting-a, stacking највећи значај даје најприлагођенијем моделу, а врло мало пажње придаје члановима који дају слабе резултате. У ансамблу су коришћени: линеарна регресија, Ridge регресија, Huber регресија, RandomForest, KNN, XGBoost и MLP, док се као мета-модел користи Ridge регресија. Huber се показао као најслабији члан, практично без доприноса.

2. Опис скупа података

Скуп података је скуп примљених радарских пулсева. Садржи 2000 сценарија, при чему сваки сценарио чини 256 узастопних пулсева (снимака) и 29 антена, што укупно даје 512.000 редова и 30 колона. Сви пулсеви једног сценарија деле исти скуп долазних углова.

Колона	Значење
angle	Долазни углови (DoA) мета у сцени, у степенима; број углова једнак је броју мета K (1–5).
ant_1 ... ant_29	Комплексна I/Q мерења сваке од 29 антена за дати пулс (реални + имагинарни део).

Табела 1. Колоне скупа података.

Геометрија низа одговара униформном линеарном низу (ULA) са размаком елемената од пола таласне дужине. Опсег долазних углова је $[-60^\circ, +60^\circ]$, а број мета K по сценарију креће се од 1 до 5 и приближно је равномерно распоређен (свака вредност око 20%). Профилисањем скупа потврђено је да нема недостајућих (NaN) вредности ни нултих редова, да су вредности нулте средње вредности са стандардном девијацијом око 0.47 по каналу, и да су све антене међусобно уједначене.

К (број мета)	Број сценарија	Удео
1	393	19.6%
2	402	20.1%
3	386	19.3%
4	423	21.1%
5	396	19.8%

Табела 2. Расподела броја мета по сценаријима.

3. Претпроцесирање података

Сирови комплексни стрингови се парсирају и раздвајају на реални и имагинарни канал, јер модели не раде са комплексним бројевима. Тиме сваки пулс постаје вектор реалних вредности. Резултат парсирања се кешира, да поновно учитавање великог скупа буде брзо.

Подаци се стандардизују (одузимање средње вредности и дељење стандардном девијацијом), при чему се статистике рачунају искључиво из тренинг скупа како не би дошло до цурења информација. Маскирање се врши по пулсу, насумично се сакрива од 1 до 10 антена, чиме се дефинишу улаз (преостале антене заједно са маском) и циљ (пуне вредности).

Подела података обавља се по сценаријима (цео сценарио припада тачно једном делу) у односу 80/10/10 на тренинг, валидациони и тест скуп. Тренинг служи за обуку чланова, валидациони за обуку мета-модела, а тест је потпуни holdout на ком се рачунају све метрике.

Провера недостајућих и аномалних вредности није захтевала додатну обраду јер су подаци чисти. Категоријских атрибута за енкодирање нема, а пошто су све антене равноправне, нема ни атрибута које би требало уклонити као небитне. Трансформације попут PCA намерно се избегавају, јер би нарушиле фазне односе међу антенама који носе кључну информацију о угловима мета.

4. Експлоративна анализа

Анализа корелација међу атрибутима спроведена је кроз процену просторне коваријационе матрице антенског низа и њених сопствених вредности. Идеално, сигнал К мета лежи у К-димензионом потпростору, па би коваријанса имала К великих сопствених вредности праћених наглим падом на шумни праг.

Међутим, на овом скупу сопствене вредности већине сценарија опадају постепено, без јасног пада после К. То значи да сигнал није смештен у чист К-димензиони потпростор — енергија му је распоређена преко више димензија него што има мета.

Процена ефективног односа сигнал-шум по сценарију (из сопствених вредности коваријансе) дала је медијану око -1.8 dB, са распоном од приближно -9.8 до $+5.8$ dB, при чему вредност расте са бројем мета. Ово је знатно ниже од декларисаних 20 dB. Поузданији показатељ од овог процениоца је сама реконструкција: пошто модел успева да предвиди око 78% вредности маскиране антене, ефективни квалитет сигнала је умерено позитиван, дакле ни -2 dB ни 20 dB. Закључак анализе је да су подаци осетно тежи од идеалног модела, што директно ограничава и реконструкцију и процену угла.

5. Одабир и опис модела

Проблем је решен **stacking** ансамблом, што омогућава поређење више класа алгоритама над истим задатком и истим тест скупом. На првом нивоу налазе се чланови:

- **Линеарна и Ridge регресија** => линеарни модели, служе као основне референце.
- **Huber регресија** => робусна линеарна регресија отпорна на одступања.
- **RandomForest и XGBoost** => стабла одлучивања и ансамбл методе.
- **KNN** => метода заснована на најближим суседима, која предвиђа из локалне сличности примера.
- **MLP** => резидуална неуронска мрежа (вишеслојни перцептрон) која учи нелинеарне, угаоно-зависне просторне корелације низа.

На другом нивоу налази се мета-модел, Ridge регресија, који комбинује предикције чланова. Кључна одлука је да се мета-модел обучава искључиво на маскираним антенама валидационог скупа: тиме он може да фаворизује најјачег члана уместо да просто просечи све, што би слаби чланови иначе погоршали. MLP члан је резидуални вишеслојни перцептрон са улазом који чине маскиран сигнал и маска (да модел увек зна које антене мора да обнови).

6. Подешавање хиперпараметара


Сprovedена је систематска претрага хиперпараметара. Сваки кандидат се тренира на тренинг скупу и оцењује реконструкцијом NMSE-ом (у децибелима, на маскираним антенама) на валидационом скупу, а резултати се рангирају. Највећи нагласак стављен је на MLP, јер он једини битно утиче на коначни резултат.

hidden	n_blocks	dropout	lr	val NMSE (dB)
512	2	0.1	0.0003	-5.86
256	4	0.0	0.001	-6.03
256	3	0.0	0.0003	-5.71
128	4	0.1	0.0003	-5.36
128	2	0.1	0.0003	-4.47

Табела 3. Најбоље конфигурације MLP-а из претраге (рангирано).

Из претраге се види да стопа учења и капацитет мреже највише утичу на резултат: $lr=0.001$ је доследно бољи, а веће вредности **hidden** и **n_blocks** помажу. Регуларизација **dropout**-ом овде не доноси побољшање (најбоља конфигурација има **dropout**=0.0), што има смисла јер су подаци тешки и модел не учи лако. За Ridge регресију промена параметра α (у опсегу од 0.01 до 100) уопште не мења резултат, јер велики број узорака чини регуларизацију небитном, што потврђује да ограничење линеарног модела лежи у природи проблема, а не у подешавању.

За KNN је подешен број суседа k . Крива грешке у зависности од k има карактеристичан облик лакта: грешка нагло опада до око $k=7-10$, а потом благо расте са превеликим k (претерано углачавање). Изабрана је вредност из тог минимума.


Слика 1. KNN: валидациони NMSE у зависности од броја суседа k (крива лакта).

7. Резултати и евалуација

Сви модели оцењени су истим скупом метрика на тест скупу: NMSE (главна мера, у dB; ниже је боље), R^2 / објашњена варијанса, MAE, средња апсолутна фазна грешка, комплексна корелација и перцентилне грешке. Метрике MAE, P95 и максимум су на стандардизованим подацима, па се читају релативно.


Модел	NMSE (dB)	ExplVar	Фаза (°)	Корелација
linear	-0.54	0.117	58.2	0.50
ridge	-0.54	0.117	58.2	0.50
huber	0.00	≈ 0	90.0	0.00
rf	-0.48	0.104	57.3	0.48
knn	-1.48	0.289	51.0	0.61
xgb	-0.83	0.174	62.3	0.45
mlp	-6.60	0.781	24.3	0.88
ENSEMBLE	-6.62	0.782	24.3	0.88

Табела 4. Реконструкционе метрике по моделу (тест скуп).



Слика 2. Поређење модела по NMSE-у (ниже је боље).

Резултати јасно показују три групе. Класични модели су слаби: линеарна, Ridge, RandomForest и XGBoost су на нивоу -0.5 до -0.8 dB, док је KNN међу њима најбољи (-1.48 dB, објашњена варијанса 0.29) јер хвата локалну сличност примера, али је и даље далеко испод MLP-а. Huber је на 0 dB практично бескористан (предвиђа приближно нулу, корелација ≈ 0 , фазна грешка 90°). MLP убедљиво доминира на -6.60 dB (објашњава $\sim 78\%$ варијансе, корелација 0.88). Ансамбл се изједначава са MLP-ом (-6.62 dB): пошто је само један члан јак, мета-модел га у суштини преузима, што и јесте исправно понашање stacking-а.



Слика 3. Реконструисани наспрам стварног сигнала за један пример (наранџасто = маскиране антене).

Грешка реконструкције расте са бројем маскираних антена, што је приказано посебном кривом.



Слика 4. NMSE у зависности од броја маскираних антена, по моделу.


7.1. Провера долазних углова (DoA)

Као доменска провера коришћен је алгоритам MUSIC, примењен на реконструисани низ и на прави низ, па су упоређени добијени углови. Циљ је да се измери колико је реконструкција очувала угаону информацију.


	Грешка угла (°)	Стопа погодака
реконструисани низ	21.63	0.385
прави низ	21.09	0.381

Табела 5. DoA резултати (просек преко 60 тест сценарија).

Кључни налаз: реконструисани низ даје практично исту тачност као прави низ (21.6° наспрам 21.1°, уз готово једнаке стопе погодака). То значи да реконструкција не квари угаону информацију. Висока апсолутна грешка последица је тежине самог задатка процене углова (до пет блиских мета, строг праг од 2°, и казна за промашене мете), а не реконструкције, што потврђује и чињеница да је грешка подједнако висока и на правом низу.



Слика 5. MUSIC спектар за један сценарио: реконструисани наспрам правог низа (испрекидано = прави углови).



Слика 6. Процењени наспрам стварних углова: реконструкција (лево) и прави низ (десно).

8. Анализа најзначајнијих чинилаца

Пошто су сви улазни атрибути (29 антена) по природи низа симетрични и равноправни, што је потврђено уједначеним статистикама по антени, класично рангирање значајности појединачних атрибута није применљиво, нити има смисла избацивати антене као небитне. Најзначајнији чинилац који утиче на излаз је број доступних (немаскираних) антена, а потом и број мета у сцени.

Овај утицај је експлицитно квантификован: NMSE расте како се повећава број маскираних антена, што се види из табеле и криве реконструкционе грешке. Број мета делује у супротном смеру, више мета отежава и реконструкцију и процену углова, што се види из разлагања DoA резултата по броју мета.

9. Deployment модела

Истренирани ансамбл се извози у датотеку (ensemble.joblib) и може се поново учитати без поновног тренирања. Око њега је направљена веб апликација (app.py, Flask) која омогућава једноставно коришћење модела: корисник генерише насумичан радарски сигнал са насумичним долазним угловима, бира колико ће антена бити маскирано, и добија графички приказ реконструисаног сигнала упоредо са стварним, уз приказ грешке на маскираним антенама. Апликација користи исти истренирани модел из пројекта, реч је о стварном раду модела, не симулацији.



Слика 7. Кориснички интерфејс: стварни наспрам реконструисаног сигнала, маскиране антене означене.

10. Карактеристични проблеми и инжењерски осврт

- **Споро парсирање великог скупа** → решено кеширањем парсираних података.
- **Слабост линеарних и дрволикх модела** → последица нелинеарне, угаоно-зависне природе проблема; решено прелазом на неуронску мрежу.
- **Склоност мета-модела ка просечавању** → решена његовим обучавањем искључиво на маскираним антенама, чиме фаворизује најјачег члана.
- **Тешко раздвајање блиских мета у процени углова** → ограничење самог MUSIC алгоритма и геометрије задатка.

Инжењерски осврт: достигнути ниво реконструкције (-6.60 dB, око 78% објашњене варијансе) близак је ономе што подаци реално дозвољавају. Анализа коваријансе и ефективног SNR-а показала је да сигнал није у чистом К-димензионом потпростору и да је ефективни квалитет нижи од декларисаних 20 dB; стога је ограничење у структури података, а не у моделу.

11. Закључак и смернице за даљи рад

Поређењем различитих класа алгоритама над истим задатком показано је да линеарни и дрволики модели не успевају да реше нелинеаран проблем реконструкције, док неуронска мрежа то постиже убедљиво најбоље. Stacking ансамбл коректно препознаје и користи најјачег члана. DoA провера потврђује да реконструкција чува угаону информацију, чиме је сачуван физички смисао података.

Смернице за даљи рад: модел који заједнички користи свих 256 пулсева једног сценарија (искоришћавање вишеструких снимака), архитектура заснована на механизму пажње (transformer по антенама), даље подешавање хиперпараметара и аугментација података. Овакви приступи су најперспективнији јер доносе информацију коју модел који ради пулс-по-пулс нема.

Прилози

Структура пројекта (главне скрипте): config.py (подешавања), data.py и features.py (учитавање и припрема), model.py и members.py (чланови), ensemble.py (stacking), metrics.py (метрике и DoA), viz.py (графика), run_ensemble.py (тренинг), test_ensemble.py (евалуација), tune.py (подешавање хиперпараметара), app.py (кориснички интерфејс).